


О методах машинного обучения

Евгений Борисов

О методах машинного обучения



О методах машинного обучения

основные формы данных

- таблицы: CSV-файлы, Excel, БД (SQL).
- текст: сообщения, отзывы, статьи и т. д.
- временные ряды: значения, упорядоченные по времени.
- изображения: файлы JPEG, PNG и др.
- аудио: звуковые файлы, WAV, MP3.
- видео: файлы AVI, videostream
- геопространственные: координаты и др.

О методах машинного обучения

ИСТОЧНИКИ ДАННЫХ ДЛЯ ЭКСПЕРИМЕНТОВ

- репозиторий библиотеки Scikit-Learn
- репозиторий UCI
- Kaggle
- WEB (Wikipedia)
- открытые БД в internet
- синтетические (сгенерированные) данные

О методах машинного обучения

EDA / Exploratory Data Analysis (анализ и визуализация данных)

- понять организацию данных
- выявить пропуски и аномалии
- проверить связи между различными признаками и целевой переменной
- сформулировать и проверить гипотезы о данных,
пример гипотезы: «клиенты-девочки тратят больше»

инструменты EDA

- визуализация данных: гистограммы, тепловые карты и т.п.
- статистический анализ: среднее, медиана, стандартное отклонение, корреляция

схема применения методов ML

признаки (*feature extraction / feature engineering*)


отображение данных, специфических для предметной области, в точки пространства признаков

Типы признаков

- количественные непрерывные ($\mathbb{R}$)
- количественные дискретные ($\mathbb{N}$)
- бинарные (да/нет)
- категориальные номинальные (цвет)
- категориальные порядковые (оценка успеваемости)
- временные отметки

собираем признаки формируем матрицу датасета

О методах машинного обучения



О методах машинного обучения

Основные типы задач ML

Классификация - разделение на части

Кластеризация - формирование групп

Регрессия - восстановление зависимости

О методах машинного обучения

Методы решения задач машинного обучения

способы организации данных

"с учителем" (supervised)

- размеченные данные

"без учителя" (unsupervised)

- не размеченные данные

"частичное обучение" semi-supervised

- частично размеченные данные

"с подкреплением" reinforcement

- датасет в явном виде отсутствует

О методах машинного обучения

Методы решения задач машинного обучения

способы организации данных

"с учителем" (supervised)

- размеченные данные

"без учителя" (unsupervised)

- не размеченные данные

"частичное обучение" semi-supervised

- частично размеченные данные

"с подкреплением" reinforcement

- датасет в явном виде отсутствует

модели

Метрические: k-Neighbors

Статистические: Naive Bayes


Логические: Decision Tree

Линейные: SVM, MLP


Композиции: AdaBoost

О методах машинного обучения

scikit-learn
algorithm cheat-sheet



О методах машинного обучения



Литература

Борисов Е.С. Методы машинного обучения. 2026
https://github.com/mechanoid5/ml_lectorium_2026_II

Борисов Е.С. Методы обработки текстов на естественном языке. 2026
https://github.com/mechanoid5/ml_nlp_2026_I

Машинное обучение для людей
https://vas3k.ru/blog/machine_learning/

Константин Воронцов - Машинное обучение. ШАД Яндекс
https://www.youtube.com/playlist?list=PLJ0zdkh8T5kp99tGTEFjH_b9zqEQiiBtC

Константин Воронцов Машинное_обучение. курс_лекций.
[http://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_\(курс_лекций,_К.В.Воронцов\)](http://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_(курс_лекций,_К.В.Воронцов))

Радослав Нейчев - Машинное обучение, ФПМИ, 2020
https://www.youtube.com/playlist?list=PL4_hYwCyhAvZyW6qS58x4uElZgAkMVUvj

Введение в Feature Engineering для начинающих дата-сайентистов и ML-инженеров
<https://habr.com/ru/companies/skillfactory/articles/842444/>